

[CC3084] Data Science

Laboratorio 6

Análítica de Redes Sociales

Nombre	Carné
Daniel Chet	231177
Dulce Ambrosio	231143
Javier Linares	231135

1 Datos y alcance

Analizamos dos archivos recolectados de YouTube. La unidad de observación de youtube_videos.csv es el video y su llave primaria es video_id. La unidad de youtube_comments.csv es el comentario principal y su llave primaria es comment_id; video_id funciona como llave foránea. La unión conserva el vínculo entre el canal que publica, el video, el autor del comentario y el comentario sin reemplazar los identificadores estables por nombres visibles.

Tabla 1. Estructura de los conjuntos de datos originales

Archivo	Unidad	Dimensión	Llave	Contenido principal
youtube_videos.csv	Video	293 × 20	video_id	Canal, título, categoría, consultas, descripción, fecha y visualizaciones
youtube_comments.csv	Comentario principal	406 × 17	comment_id	video_id, autor, texto, me gusta, respuestas y procedencia

Los 406 comentarios se asociaron con un video, por lo que la integración alcanzó una cobertura de 100 %. Los comentarios corresponden a 19 videos, 7 canales y 332 autores únicos. Los otros 274 videos no tienen comentarios recolectados. Este último dato describe la cobertura del archivo y no prueba que esos videos carezcan de comentarios en YouTube.

Relaciones entre entidades

Un canal puede publicar varios videos y cada video pertenece a un canal. Un autor puede publicar uno o más comentarios en uno o más videos. La categoría y la consulta de búsqueda describen al video y al procedimiento de recolección, respectivamente. source_query no se trató como una etiqueta temática definitiva porque indica cómo se encontró el registro. reply_count solo registra la cantidad de respuestas recibidas y no identifica quién respondió; por eso no se construyeron aristas entre autores a partir de esa variable.

2 Calidad y preprocesamiento

Tabla 2. Diagnóstico y tratamiento de calidad

Aspecto	Hallazgo	Decisión
Llaves primarias	0 video_id y 0 comment_id duplicados	Se conservaron como identificadores de red
Integración	406 de 406 comentarios asociados	Unión por video_id
viewer_rating	406 valores faltantes	Se excluyó de los análisis
is_pinned	Valor False en todos los registros	Variable constante sin poder explicativo
Variables redundantes	publish_date = upload_date; channel_handle = owner_handle	Se evitó duplicar señales y se mantuvo channel_id como ID estable
Conteos en texto	Separadores, espacios y vacíos	Se transformaron a enteros; los no válidos se trataron como faltantes
Valores extremos	Máximo de 8 190 449 visualizaciones	Se mantuvieron y se usó escala logarítmica en gráficos

Los nombres de las columnas y los textos originales se conservaron en su idioma y forma de recolección. No se tradujeron los comentarios porque la traducción puede alterar modismos, negaciones, ironía y contexto. Para auditoría se mantuvo texto_original; texto_limpio se derivó para frecuencias y temas.

La limpieza convirtió a minúsculas, eliminó URL y puntuación, separó hashtags, menciones y emojis, retiró números y stopwords en español y produjo una representación destinada al análisis léxico. La lematización no se aplicó de forma agresiva para evitar cambios de significado en nombres propios y lenguaje informal. El sentimiento se calculó siempre sobre texto_original.

Tabla 3. Efecto cuantificado de la limpieza de texto

Indicador	Resultado
Textos originales vacíos	0
Textos limpios vacíos	8
Duplicados exactos antes	2
Duplicados exactos después	12
Registros modificados por la limpieza	396
Registros eliminados	0

3 Participación observada

Tabla 4. Magnitud de la muestra y participación

Indicador	Resultado	Lectura
Videos	293	19 con comentarios recolectados
Canales	97	7 con comentarios recolectados
Comentarios	406	Todos vinculados por video_id
Autores	332	9 participaron en más de un video
Video más comentado	161 comentarios	Qué rico come tu diputado
Canal más comentado	256 comentarios	Quorum

La concentración aparece tanto por video como por canal. El video con más actividad reúne 39,7 % de todos los comentarios; los cinco primeros reúnen 75,4 % y los diez primeros 93,6 %. Quorum concentra 63,1 % y los cinco canales más activos 96,1 %.




Figura 1. Concentración de comentarios por video y canal. Fuente: elaboración propia con los datos recolectados.

Tabla 5. Videos con mayor participación observada

Video	Canal	Comentarios	Autores	Vistas
Qué rico come tu diputado	Quorum	161	128	11 775
La cooptación de Walter Mazariegos en la USAC	Quorum	50	49	10 156
Inician los trabajos de recuperación del Puente Bel...	Gobierno de la Repúblic...	45	32	11 670
Plan 2032 Ciudad de Guatemala	Municipalidad de Guatem...	25	25	304 089
Conferencia de Prensa del Gobierno de Guatemala. #L...	Gobierno de la Repúblic...	25	19	3 628
EE.UU. envía a mexicanos deportados a Guatemala ant...	Noticias Telemundo	25	18	14 200
Arroz con pollo a la MONOPOLIO	Quorum	16	16	1 954
Capturan a presuntos delincuentes disfrazados de mu...	Noti7	14	13	6 692

Tabla 6. Canales con comentarios recolectados

Canal	Videos	Comentarios	Autores	Proporción
Quorum	11	256	214	63,1 %
Gobierno de la República de Guatemala...	2	70	50	17,2 %
Municipalidad de Guatemala	1	25	25	6,2 %
Noticias Telemundo	1	25	18	6,2 %
Noti7	1	14	13	3,4 %
PrensaLibreOficial	1	7	7	1,7 %
TN23 Guatemala	1	7	7	1,7 %

Popularidad y comentarios

La correlación de Spearman entre visualizaciones y comentarios fue $\rho = 0,0803$ con $p = 0,1703$ para 293 videos. El coeficiente es cercano a cero y no aporta evidencia de una relación monótonica en esta muestra. Un video con muchas visualizaciones no necesariamente aparece con muchos comentarios porque la captura de comentarios cubrió solo una selección de videos y porque ambos conteos se observaron en momentos y condiciones distintas.




Figura 2. Visualizaciones y comentarios recolectados por video. El eje de visualizaciones usa escala logarítmica.

4 Red bipartita de autores y videos

La red bipartita es no dirigida y contiene dos tipos de nodo: autores y videos. Existe una arista cuando un autor publicó al menos un comentario en un video. El peso de la arista es la cantidad de comentarios de ese autor en ese video. Esta relación representa coparticipación registrada; no representa amistad, respuesta directa, acuerdo ni aprobación del contenido.

La red contiene 625 nodos y 343 aristas únicas. El peso total de las aristas es 406, igual al número de comentarios. La diferencia de 63 entre aristas y comentarios se debe a que los comentarios repetidos de un mismo autor en un video se agregan en una sola relación ponderada. Los 274 videos sin comentarios aparecen como nodos aislados para mantener la cobertura completa del catálogo.

Red bipartita completa de autores y videos



Los nodos periféricos incluyen los 274 videos sin comentarios recolectados.

Figura 3. Red bipartita completa. Los videos aislados se conservaron y se muestran en la periferia.


Tabla 7. Aristas autor video con mayor peso

Autor	Video	Peso	Canal
/@eugeneramirez4405	EE.UU. envía a mexicanos deportados a Guate...	6	Noticias Telemundo
/@Murmullodelbarrio	Inician los trabajos de recuperación del Pu...	6	Gobierno de la Repúbl...
/@albertosherandez5251	Inician los trabajos de recuperación del Pu...	5	Gobierno de la Repúbl...
/@ManuelEdran	Qué rico come tu diputado	5	Quorum
/@ErvinLeonardoCarreraL...	Qué rico come tu diputado	4	Quorum
/@juandeleon9060	Conferencia de Prensa del Gobierno de Guate...	3	Gobierno de la Repúbl...
/@ErmeP%C3%A9rez-q4s	Conferencia de Prensa del Gobierno de Guate...	3	Gobierno de la Repúbl...
/@marioajset4283	Qué rico come tu diputado	3	Quorum
/@osmanmorales3012	Qué rico come tu diputado	3	Quorum
/@HaroldoCastillo-rh9iw	Qué rico come tu diputado	3	Quorum

5 Proyecciones y topología


La proyección autor a autor conecta a dos autores cuando comentaron el mismo video; su peso es el número de videos compartidos. La proyección video a video conecta dos videos cuando comparten al menos un autor; su peso es el número de autores compartidos. Las proyecciones responden preguntas distintas y amplifican de manera diferente los videos populares.

Proyección autor autor



Conexión si dos autores comentaron el mismo video.

Proyección video video



Conexión si dos videos comparten al menos un autor.

Figura 4. Proyecciones de la red. La alta densidad visual entre autores proviene de la coparticipación en pocos videos populares.

Tabla 8. Métricas de topología y fragmentación

Red	Nodos	Aristas	Densidad	Grado medio	Aislados	Componentes	Componente mayor
Bipartita	625	343	0,0018	1,10	274	284	286 (45,8 %)
Autor autor	332	10 732	0,1953	64,65	4	10	276 (83,1 %)
Video video	293	11	0,0003	0,08	283	284	10 (3,4 %)

La red bipartita es muy fragmentada: tiene densidad 0,00176, 284 componentes y una componente mayor de 286 nodos, equivalente al 45,8 % del total. Su conectividad global es cero por la presencia de aislados; dentro de la componente mayor es uno, por lo que basta eliminar un nodo articulador para separar alguna parte de esa estructura. Se identificaron 22 puntos de articulación.

La proyección de autores tiene 10 732 aristas, densidad 0,195 y transitividad 0,984. La transitividad elevada es un efecto esperado de proyectar grupos de comentaristas: los autores que participan en el mismo video forman cliques. No debe interpretarse como cohesión social independiente. La componente mayor reúne 276 autores, pero cuatro autores quedan aislados en la proyección porque comentaron videos sin otros autores.

La proyección de videos presenta el patrón opuesto. Solo tiene 11 aristas, 283 aislados y 284 componentes. Su componente mayor contiene diez videos, el 3,4 % del catálogo. Entre los 19 videos comentados, nueve no comparten autores con otro video. Esta estructura respalda la conclusión de que la audiencia cruzada observada es limitada.

6 Comunidades de audiencia compartida

La detección de comunidades se aplicó a la parte activa de la proyección video a video. Esta red responde directamente a la pregunta de qué contenidos comparten audiencia. Se utilizó Louvain con pesos de autores compartidos y semilla 42. El algoritmo encontró tres comunidades de tamaños 4, 3 y 3, con modularidad 0,4053. La modularidad indica una separación moderada dentro de una red muy pequeña y debe interpretarse junto con su cobertura de solo diez videos.

Comunidades en la audiencia compartida entre videos




Figura 5. Tres comunidades detectadas entre los diez videos con audiencia compartida.

Tabla 9. Perfil cuantitativo de las comunidades

ID	Videos	Canales	Autores	Comentarios	Sentimiento	Términos frecuentes
1	4	3	187	225	-0,552	no, pueblo, dinero, diputados, trabajo
2	3	2	62	84	-0,206	no, presidente, guatemala, país, años
3	3	1	29	34	-0,098	no, excelente, empresas, internet, ley

Comunidad 1. Agrupa 4 videos de 3 canales, 187 autores y 225 comentarios. Quorum, Prensa Libre y TN23 conectan contenidos sobre diputados, recursos públicos, trabajo y universidad. El sentimiento medio es -0,552 y 74,7 % de los comentarios fueron clasificados como negativos. Es la comunidad más grande y concentra el tono crítico más intenso.

Comunidad 2. Reúne 3 videos de 2 canales, 62 autores y 84 comentarios. Los contenidos de Gobierno de la República y Noti7 se enlazan por una audiencia recurrente pequeña. Los términos frecuentes se relacionan con presidente, Guatemala, país y años. El sentimiento medio es -0,206; la proporción negativa alcanza 53,6 %.

Comunidad 3. Incluye 3 videos de Quorum, 29 autores y 34 comentarios. Los términos ley, empresas, internet y excelente distinguen esta agrupación. Su sentimiento medio es

-0,098 y 38,2 % de los comentarios fueron positivos, la proporción positiva más alta entre las tres comunidades.

7 Centralidad y participantes puente

Se calcularon grado, grado ponderado, intermediación, PageRank y puntos de articulación en la red bipartita. El grado mide cuántos vecinos distintos tiene un nodo; el grado ponderado incorpora la cantidad de comentarios; la intermediación identifica nodos ubicados en rutas cortas entre partes de la red; PageRank resume importancia estructural; y un punto de articulación separa componentes cuando se elimina.




Figura 6. Nodos con mayor intermediación, separados por tipo.

Tabla 10. Autores recurrentes con mayor intermediación

Autor	Videos	Comentarios	Intermediación	Articulador
/@virgiliogarcia3039	2	3	0,072766	Sí
/@inge_vergueta	3	3	0,068522	Sí
/@josegil3813	2	2	0,055562	Sí
/@Jel.Awesh.M	2	3	0,028013	No
/@hashojea7348	3	4	0,018760	Sí

Tabla 11. Videos con mayor centralidad estructural

Video	Autores	Comentarios	Intermediación	PageRank	Articulador
Qué rico come tu diputado	128	161	0,177748	0,1497	Sí
Conferencia de Prensa del Gobierno de Guatemala....	19	25	0,076676	0,0223	Sí
La cooptación de Walter Mazariegos en la USAC	49	50	0,071475	0,0565	Sí
Inician los trabajos de recuperación del Puente B...	32	45	0,058953	0,0381	Sí
Internet: escoger el menos malo	10	12	0,040311	0,0119	Sí

Qué rico come tu diputado es el video articulador principal: tiene grado 128, grado ponderado 161, intermediación 0,177748 y PageRank 0,1497. Su centralidad proviene de reunir a 128 autores y de conectar participantes que también aparecen en otros contenidos. Entre autores, los valores de intermediación son mucho menores porque solo 9 cuentas participan en más de un video.

Se identificaron 7 autores y 15 videos como puntos de articulación cuando la clasificación se separa por tipo de nodo. Estos resultados muestran dependencia estructural en pocos puentes. No convierten a esos autores en influenciadores fuera de la red observada, porque la centralidad se calcula con una muestra parcial de comentarios.

8 Contenido y sentimiento

El sentimiento se estimó con cardiffnlp/twitter-xlm-roberta-base-sentiment, un modelo multilingüe basado en XLM RoBERTa y ajustado para texto de redes sociales. El modelo acepta español y permite clasificar los comentarios originales sin traducirlos. Para cada comentario se conservaron las probabilidades negativa, neutral y positiva, la etiqueta con mayor probabilidad, la confianza y una puntuación continua calculada como probabilidad positiva menos probabilidad negativa.




Figura 7. Distribución general de sentimiento y comparación por canal con al menos cinco comentarios.

Tabla 12. Resultado general del análisis de sentimiento

Indicador	Resultado	Interpretación
Negativo	256	63,1 %
Neutral	58	14,3 %
Positivo	92	22,7 %
Puntuación media	-0,3508	Escala aproximada de -1 a 1

Confianza media	0,7774	Probabilidad de la etiqueta elegida
-----------------	--------	-------------------------------------

Tabla 13. Sentimiento medio por canal con cinco o más comentarios

Canal	n	Puntuación	Lectura descriptiva
TN23 Guatemala	7	-0,707	Predominio negativo
PrensaLibreOficial	7	-0,622	Predominio negativo
Noticias Telemundo	25	-0,569	Predominio negativo
Quorum	256	-0,449	Predominio negativo
Gobierno de la República de Guatemala	70	-0,209	Predominio negativo
Noti7	14	-0,193	Predominio negativo
Municipalidad de Guatemala	25	0,567	Predominio positivo

El 63,1 % de los comentarios fue clasificado como negativo. TN23 y Prensa Libre presentan los promedios más negativos, aunque ambos tienen solo siete comentarios; Noticias Telemundo y Quorum combinan mayor muestra con promedios también negativos. La Municipalidad de Guatemala es el único canal con promedio claramente positivo. Estas diferencias describen los comentarios recolectados y pueden estar asociadas con el tema de los videos, la audiencia atraída o el procedimiento de muestreo; el análisis no permite atribuir causalidad al canal.

El modelo fue entrenado en publicaciones de redes sociales y no específicamente en comentarios guatemaltecos de YouTube. La ironía, el sarcasmo, los modismos, los errores ortográficos y los cambios de significado según el contexto pueden producir clasificaciones incorrectas. No se contó con una muestra etiquetada manualmente para estimar precisión local, por lo que las proporciones se tratan como una aproximación descriptiva.

9 Preguntas del análisis

Tabla 14. Respuestas a las preguntas obligatorias

Pregunta	Respuesta sustentada
Qué concentra la participación	Qué rico come tu diputado aporta 161 comentarios; Quorum aporta 256 de 406 (63,1 %).
Si existen audiencias compartidas	Solo diez videos forman la componente activa de la proyección video a video; 283 videos son aislados.
Quién funciona como puente	Nueve autores participaron en más de un video; siete autores son puntos de articulación en la red bipartita.
Qué caracteriza las comunidades	Tres comunidades con modularidad 0,405; la mayor es la más negativa y la tercera tiene la mayor proporción positiva.
Si visibilidad coincide con participación	No se observó una asociación monotónica clara: $p = 0,080$, $p = 0,170$.
Qué limita las conclusiones	Cobertura desigual, consultas de selección, fechas relativas, conteos de una captura y ausencia de relaciones explícitas entre autores.

Preguntas adicionales

1. ¿La recurrencia entre videos es una conducta común?
 - a. No, ya que solo 9 de 332 autores comentaron en más de un video, equivalente a 2,7 %. Por eso, la audiencia compartida depende de una minoría pequeña.
2. ¿La actividad se distribuye de manera estable entre contenidos?
 - a. No en la muestra porque los cinco videos más activos concentran 75,4 % de los comentarios y los diez primeros 93,6 %. Los resultados agregados están dominados por pocos contenidos.
3. ¿Todos los canales presentan el mismo tono?
 - a. No, debido a que la municipalidad de Guatemala obtuvo una puntuación media de 0,567 en 25 comentarios, mientras los otros canales con cinco o más comentarios tuvieron promedios cercanos a neutral o negativos. La diferencia merece revisión temática, pero no prueba que el canal cause el tono.

10 Interpretación integrada

El patrón conjunto describe una participación episódica. Muchos videos forman parte del catálogo recolectado, pero los comentarios se concentran en unos pocos contenidos. Dentro de cada video popular, numerosos autores coinciden y producen una proyección autor a autor densa. Fuera de esos espacios, casi no hay repetición entre videos. La red combina agrupamientos locales grandes con muy pocos enlaces entre contenidos.

Los videos articuladores son importantes porque conectan los pocos autores recurrentes con conjuntos de comentaristas que, de otra forma, quedarían separados. El video sobre diputados domina comentarios, autores, intermediación y PageRank; esta coincidencia muestra que la centralidad depende de la participación observada. Los autores puente conectan temas o canales, pero su recurrencia es demasiado limitada para describir una audiencia estable de todo el ecosistema.

El predominio de sentimiento negativo coincide con contenidos políticos, institucionales, migratorios y de seguridad presentes en las comunidades principales. La comunidad más grande reúne el mayor volumen y el tono más negativo. La tercera comunidad, centrada en contenidos de Quorum sobre empresas, internet y ley, muestra una composición menos negativa. La relación entre tema y sentimiento es descriptiva porque la selección no fue aleatoria y las comunidades contienen pocos videos.

11 Limitaciones

Tabla 15. Limitaciones y efecto sobre la interpretación

Limitación	Evidencia	Implicación
Cobertura de comentarios	Solo 19 de 293 videos tienen comentarios recolectados.	Los aislados pueden representar ausencia de captura y no ausencia real de participación.

Selección por consultas	Los registros provienen de búsquedas y canales específicos.	La muestra no representa todo YouTube ni todas las conversaciones de Guatemala.
Fechas relativas	published_text usa expresiones como hace dos semanas.	No permite reconstruir con exactitud la secuencia temporal sin la fecha de captura.
Conteos de una captura	Vistas, me gusta y respuestas cambian con el tiempo.	Las comparaciones describen un momento y pueden variar después.
Relaciones explícitas	reply_count no identifica autores ni textos de respuesta.	La red mide coparticipación, no conversación directa.
Concentración	Pocos videos y canales dominan los 406 comentarios.	Los promedios generales reflejan sobre todo esos contenidos.
Proyección	Un video popular crea muchas aristas autor a autor.	Densidad y transitividad pueden inflarse mecánicamente.
Sentimiento	El modelo no fue validado con etiquetas humanas locales.	Sarcasmo, modismos y errores pueden cambiar la clasificación.

Estas limitaciones obligan a distinguir descripción, asociación e inferencia. Los conteos, métricas y proporciones describen la muestra. La correlación entre vistas y comentarios y las diferencias de sentimiento son asociaciones. No se realizaron inferencias causales ni se extrapolaron los resultados a todos los usuarios de YouTube o a la población guatemalteca.

12 Conclusiones

- La participación observada está concentrada: un video aporta 39,7 % de los comentarios y un canal 63,1 %.
- La audiencia compartida entre videos es limitada: 283 de 293 videos son aislados en la proyección y solo nueve autores participan en más de un video.
- El sentimiento general es predominantemente negativo, pero la variación por canal y comunidad debe leerse como descripción de una muestra sesgada por cobertura.
- Las visualizaciones no muestran una relación clara con los comentarios recolectados, de modo que visibilidad y participación representan dimensiones diferentes en estos datos.

Referencias

1. Universidad del Valle de Guatemala. Laboratorio 6 Análisis de redes sociales. CC3084 Data Science, semestre II de 2026.
2. NetworkX Developers. NetworkX documentation.
<https://networkx.org/documentation/stable/>
3. Cardiff NLP. twitter-xlm-roberta-base-sentiment model card.
<https://huggingface.co/cardiffnlp/twitter-xlm-roberta-base-sentiment>
4. Blondel, V. D., Guillaume, J. L., Lambiotte, R. y Lefebvre, E. Fast unfolding of communities in large networks. Journal of Statistical Mechanics, 2008.