

Data Science

Spark MLlib: Segmentación y Predicción del Salario

INTRODUCCIÓN

Tras aplicar los criterios de población (personas de 15+ años, ocupadas, asalariadas y con salario positivo registrado), la muestra analítica de 2025 quedó en 53,025 registros y la de 2026 T1 en 13,258 registros. La segmentación con KMeans identificó dos perfiles de trabajadores diferenciados principalmente por antigüedad y edad. En el modelado supervisado, Random Forest superó consistentemente a la Regresión Lineal y a un modelo de referencia (predicción de la media), tanto en validación como en la prueba final sobre 2026 T1 ($R^2 \approx 0.53$ vs. 0.43 vs. ≈ 0). El hallazgo más relevante del análisis de errores es que ambos modelos sobreestiman sistemáticamente los salarios bajos y subestiman fuertemente los salarios del percentil 95-100, donde el error absoluto medio se multiplica varias veces respecto al resto de la distribución.

CONTEXTO Y OBJETIVO DEL ANÁLISIS

El estudio de los salarios permite identificar diferencias entre grupos de trabajadores, comprender su relación con la educación y las condiciones laborales, y generar evidencia para orientar programas de capacitación y análisis del mercado de trabajo. Este análisis responde dos preguntas:

1. ¿Qué perfiles de trabajadores asalariados pueden identificarse según variables como edad, antigüedad y jornada habitual?
2. ¿Qué tan bien puede estimarse el salario mensual de una persona asalariada utilizando características personales y laborales observadas?

DATOS Y METODOLOGÍA

Fuente y períodos

Se utilizaron las bases de Personas de la ENEIC (Instituto Nacional de Estadística de Guatemala), los cuatro trimestres de 2025 para desarrollo y entrenamiento, y el primer trimestre de 2026 para la evaluación final. Cada archivo se identificó por su procedencia (`archivo_origen`), asignando `periodo_archivo`, `anio_archivo` y `trimestre_calendario` según el archivo, no según el campo crudo `TRIMESTRE`, cuyos valores no corresponden directamente al trimestre calendario.

El archivo de IV de 2025 tiene 302 columnas en lugar de 270, las variables comunes no ocupan la misma posición ordinal, por lo que los cuatro archivos de 2025 se unieron con `unionByName` (alineación por nombre de columna, no por posición).

Población analítica y variable objetivo

El análisis se limita a personas que cumplen, simultáneamente:

- 15 años o más, con edad finita registrada.
- Ocupadas (OCUPADOS = 1).
- Asalariadas según P05C16 $\in \{1, 2, 3, 4\}$: empleado de gobierno, empleado de empresa privada, empleado jornalero o peón, y servicio doméstico.
- Con salario_mensual (P05D01) numérico, finito y estrictamente positivo.

No se sustituyó el objetivo por YLAB_PUBLI ni se sumaron otros componentes de ingreso, no se imputó el salario, los registros sin salario positivo se excluyeron y se contabilizaron. No se recortaron outliers de salario en la comparación principal de modelos.

Predictores

Los modelos supervisados usan exactamente seis predictores, edad, antigüedad (= años + meses/12, calculada a partir de P05C07A y P05C07B), horas_semanales, nivel_educativo, categoria_ocupacional y dominio. No se incluyeron identificadores, el factor de expansión, otros montos de ingreso, el salario por hora derivado del objetivo ni la etiqueta de clúster.

Los códigos categóricos se homologaron a una representación de texto consistente (un mismo código podía llegar como número o como texto). Los valores ausentes o no reconocidos se marcaron como “DESCONOCIDO”, nunca como 0, ya que el código educativo 0 (ninguno) es una categoría válida, no un faltante.

CARGA, ARMONIZACIÓN Y CALIDAD DE DATOS

Registros por archivo antes de aplicar filtros:

Período	Registros
2025 T1	51,588
2025 T2	51,167
2025 T3	51,583
2025 T4	49,338
Total 2025 (unión)	203,676

Porcentaje de valores faltantes por variable seleccionada (antes de filtros, sobre 203,676 registros de 2025):

Variable	Faltantes	% faltantes
edad	0	0.00%
DOMINIO	0	0.00%
nivel_educativo	26,344	12.93%
antigüedad_anios	115,454	56.69%
antigüedad_meses	115,454	56.69%
horas_semanales	115,454	56.69%
categoria_ocupacional	115,454	56.69%
ocupado	115,454	56.69%
salario_mensual	150,651	73.97%

Estos porcentajes altos son esperados, ya que la mayoría de las preguntas de la sección laboral (antigüedad, horas, categoría ocupacional, salario) no corresponden a la mayor parte de la muestra de la encuesta (menores de edad, no ocupados, etc.), son ausentes, o no corresponde, distintos de una respuesta no registrada por quien sí debía contestarla.

Cascada de filtros (2025, mismo orden en ambas bases)

Paso	Antes	Después	Excluidos
Edad válida (<i>finita</i> , ≥ 15)	203,676	140,790	62,886
Ocupado (<i>OCUPADOS</i> = 1)	140,790	88,222	52,568
Asalariado (<i>categoría</i> $\in \{1,2,3,4\}$)	88,222	53,025	35,197
Salario válido (<i>finito</i> , > 0)	53,025	53,025	0
Antigüedad en años ≥ 0	53,025	53,025	0
Antigüedad en meses entero 0-11	53,025	53,025	0
Horas semanales > 0 y ≤ 168	53,025	53,025	0
Antigüedad calculada $\leq$ edad	53,025	53,025	0

El mismo procedimiento aplicado a 2026 T1 (49,843 registros crudos) deja 13,258 registros analíticos de prueba. No se encontraron combinaciones duplicadas de periodo_archivo + NUM_HOGAR + NUM_PERSONA en ninguna de las dos bases preparadas.

Una persona observada en dos trimestres no se elimina como duplicado, la ENEIC tiene diseño longitudinal con rotación, por lo que la misma persona puede entrevistarse legítimamente en varios períodos. El número de registros de la base filtrada tampoco representa a todos los trabajadores del país, porque el análisis es no ponderado (no usa FACTOR) y está restringido a personas ocupadas, asalariadas y con salario positivo registrado.

ESTADÍSTICA DESCRIPTIVA

Estadísticos sobre la población analítica completa de 2025 (n = 53,025):

Variable	Media	Mediana	Desv. Est.	Mín	P25	P75	P95	Máx
Salario mensual (Q)	3,421.68	3,000.0	2,902.11	1.0	1,800.0	4,000.0	8,000.0	99,000.0
Edad (años)	35.19	33.0	13.52	15.0	24.0	44.0	61.0	89.0
Antigüedad (años)	5.56	2.0	7.83	0.0	0.5	7.0	21.5	70.0
Horas semanales	46.31	45.0	18.63	1.0	40.0	55.0	80.0	126.0




Figura 1. Distribución de registros por categoría ocupacional, nivel educativo y dominio.




Figura 2. Distribución del salario mensual en escala original y en escala logarítmica

El salario mensual tiene distribución asimétrica a la derecha, la media (Q3,421.68) es mayor que la mediana (Q3,000.00), una diferencia de Q421.68, típica de variables de ingreso donde una minoría de salarios altos estira la cola derecha de la distribución.




Figura 3. Salario mediano por nivel educativo y por categoría ocupacional.




Figura 4. Tamaño de la muestra analítica y salario mediano por trimestre (2025).

El tamaño de la muestra analítica se mantiene relativamente estable entre trimestres (~12,700 – 13,500 registros), y el salario mediano sube de Q3,000 en T1-T2 a Q3,200 en T3-T4.

CORRELACIONES ENTRE VARIABLES NUMÉRICAS

Correlación de Pearson (VectorAssembler + Correlation.corr de pyspark.ml.stat), calculada sobre todos los registros elegibles de 2025:




Figura 5. Mapa de calor de la matriz de correlación de Pearson.

Ninguna de las tres variables numéricas tiene una asociación lineal fuerte con el salario, antigüedad y edad son débiles positivas, y horas semanales ($r \approx 0.08$) es prácticamente nula. La asociación más fuerte de la matriz es entre edad y

antigüedad ($r \approx 0.49$, positiva moderada), las personas mayores tienden a tener más años en su empleo actual, aunque la relación no es estrecha porque la antigüedad también depende de cuándo inició el empleo actual.

SEGMENTACIÓN DE PERFILES MEDIANTE KMEANS

Variables de segmentación: edad, antigüedad y horas_semanales (estandarizadas). No se incluyó salario_mensual, ya que es la variable objetivo del modelado supervisado posterior y, por su escala y dispersión, dominaría la distancia euclidiana del KMeans si se incluyera sin más consideración

k	Silhouette	WSSSE
2	0.5532	106,718.7
3	0.4721	83,608.1
4	0.4764	64,438.5
5	0.4146	58,304.3




Figura 6. Silhouette y WSSSE por número de clústers k.

Se eligió $k = 2$ por tener el silhouette más alto, claramente por encima de $k = 3, 4$ y 5 , la segmentación se vuelve menos nítida al agregar más grupos, y el WSSSE no muestra un codo marcado que justifique sacrificar cohesión por más grupos.

Clúster	n	Edad media	Antigüedad media	Horas media	Salario mediano
0 — “senior / alta antigüedad”	14,701	51.23	13.74	41.25	Q3,456
1 — “joven / poca antigüedad”	38,324	29.03	2.42	48.25	Q3,000

El clúster 0 (27.7% de la muestra) agrupa trabajadores establecidos, con jornada cercana a tiempo completo estándar y el salario mediano más alto, proporcionalmente concentra más empleados de gobierno (23.5% de ese clúster frente a 8.1% del otro). El clúster 1 (72.3% de la muestra) es el perfil predominante, joven, de baja antigüedad, jornada más larga y salario mediano más bajo,

mayoritariamente empleados de empresa privada (58.6%). La segmentación separa sobre todo por antigüedad/edad (diferencia de ~11 años en antigüedad), no tanto por horas trabajadas, y el clúster de mayor antigüedad tiene un salario mediano ~15 más alto.

MODELADO SUPERVISADO: REGRESIÓN LINEAL Y RANDOM FOREST

Se estima salario_mensual a partir de los seis predictores indicados. Siguiendo la tabla de archivos del enunciado (IV de 2025: “validación y posterior entrenamiento final”), se usó el siguiente esquema:

- Entrenamiento (selección de hiperparámetros): 2025 T1+T2+T3 (n = 40,361).
- Validación: 2025 T4 (n = 12,664), usada para elegir la configuración de menor RMSE de cada algoritmo.
- Entrenamiento final: una vez elegida la configuración, se reentrena con todo 2025 (T1-T4, n = 53,025).
- Prueba final: 2026 T1 (n = 13,258), nunca usada para entrenar ni para elegir hiperparámetros.

Ambos pipelines comparten StringIndexer + OneHotEncoder para las variables categóricas (nivel_educativo, categoria_ocupacional, dominio) y VectorAssembler para combinarlas con las numéricas (edad, antigüedad, horas_semanales). La Regresión Lineal usa su estandarización interna (standardization=True); Random Forest no requiere estandarización.

Modelo de referencia

Predice, para todo registro, el salario promedio de entrenamiento (Q3,383.12 en la etapa de validación), sin usar ningún predictor. En validación (2025 T4): MAE = Q1,672.50, RMSE = Q2,889.57, $R^2 \approx -0.003$ (por construcción, cercano a 0).

Regresión Lineal - configuraciones de regularización (validación)

regParam	elasticNetParam	MAE	RMSE	R^2
0.00	0.0 (sin regularización)	1,210.14	2,186.42	0.4257
0.01	0.0 (ridge suave)	1,210.14	2,186.42	0.4257
0.10	0.0 (ridge)	1,210.13	2,186.42	0.4257
0.10	1.0 (lasso)	1,210.09	2,186.43	0.4257

Las cuatro configuraciones dan prácticamente el mismo resultado (con solo 6 predictores, el modelo no está sobreajustando, así que penalizar coeficientes casi no cambia nada). La mejor por RMSE es regParam = 0, elasticNetParam = 0. Frente a la referencia, la Regresión Lineal reduce el RMSE en más de 20% y el MAE en más de 25%, con $R^2 \approx 0.43$.

Random Forest — configuraciones (validación, semilla fija)

numTrees	maxDepth	MAE	RMSE	R^2
40	5	1,155.93	2,157.90	0.4406
80	8	1,095.84	2,042.85	0.4986
80	10	1,076.20	1,991.71	0.5234

El RMSE baja consistentemente al aumentar numTrees/maxDepth en el rango probado, sin señales de sobreajuste todavía. La mejor configuración (80 árboles, profundidad 10) supera claramente a la mejor Regresión Lineal, Random Forest puede capturar interacciones no lineales entre las variables categóricas, mientras que la Regresión Lineal solo suma efectos lineales independientes.

Entrenamiento final y evaluación en 2026 T1

Con la configuración ganadora de cada algoritmo, reentrenada con todo 2025 y evaluada sobre los mismos registros elegibles de 2026 T1:

Modelo	MAE	RMSE	R^2
Referencia (media)	1,718.09	2,871.42	-0.0025
Regresión Lineal	1,240.71	2,163.75	0.4307
Random Forest	1,103.90	1,962.58	0.5317

Random Forest vuelve a superar a la Regresión Lineal y ambos superan claramente a la referencia, de forma consistente con validación, buena señal de que la selección de configuración con 2025 T4 generaliza a un trimestre y año distintos (2026 T1).

Visualización y análisis de errores

El residuo se define como `salario_mensual - prediction`, positivo indica subestimación (el modelo predijo menos que el valor real) y negativo indica sobreestimación. Los gráficos de dispersión usan la misma muestra ($\leq 5,000$ registros, misma semilla) para ambos modelos; las métricas por grupo se calculan con todos los registros de prueba (13,258).




Figura 7. Salario real vs. predicho, con línea de referencia $y = x$ (muestra de prueba, $n \approx 5,000$).




Figura 8. Residuos vs. salario predicho, con línea horizontal en cero.

MAE y error medio por nivel educativo y por dominio (todos los registros de prueba)

Regresión Lineal — por nivel educativo

Nivel educativo	n	MAE	Error medio
0 (ninguno)	1,016	823.5	109.3
1	80	735.2	88.8
2	3,957	870.0	54.6
3	2,164	894.5	127.8
4	4,117	1,109.3	104.0
5	1,729	2,566.4	295.5
6	183	5,552.9	-131.5
7	12	12,919.3	6,062.7

Regresión Lineal — por dominio

Dominio	n	MAE	Error medio
1	5,632	1,446.1	136.0
2	4,846	1,189.6	134.3
3	2,780	913.6	65.2

Random Forest — por nivel educativo

Nivel educativo	n	MAE	Error medio
0 (ninguno)	1,016	655.9	-43.5
1	80	628.0	-106.8
2	3,957	754.2	43.6
3	2,164	820.9	135.0
4	4,117	1,019.6	126.5
5	1,729	2,301.1	277.5
6	183	4,643.7	-224.5
7	12	10,986.6	6,132.5

Random Forest — por dominio

Dominio	n	MAE	Error medio
1	5,632	1,320.2	169.9
2	4,846	1,043.4	93.7
3	2,780	771.1	12.2

Los niveles educativos 6 y, sobre todo, 7 muestran errores absolutos mucho mayores que el resto pero tienen muy pocas observaciones (183 y 12, respectivamente), por lo que esas estimaciones de error deben interpretarse con cautela.

¿Los modelos subestiman o sobreestiman los salarios altos?

Percentiles de salario en la prueba:

$$P_{25} = Q_{2,000} | P_{50} = Q_{3,200} | P_{75} = Q_{4,066} | P_{95} = Q_{8,000}.$$

Regresión Lineal, por percentil de salario

Percentil	n	Error medio	MAE
P0-25	4,032	-828.7	998.4
P25-50	2,715	-161.1	851.7
P50-75	3,188	-79.6	830.8
P75-95	2,680	746.6	1,381.5
P95-100	643	5,645.3	5,848.4

Random Forest, por percentil de salario

Percentil	n	Error medio	MAE
P0-25	4,032	-763.7	851.4
P25-50	2,715	-160.4	684.9

P50-75	3,188	-42.6	738.5
P75-95	2,680	722.9	1,369.0
P95-100	643	4,911.3	5,163.6




Figura 9. Error medio por percentil de salario, ambos modelos (prueba 2026 T1).

El patrón es consistente en ambos modelos: el error medio es negativo (sobreestimación) en P0-25 a P50-75, se vuelve positivo en P75-95, y es marcadamente positivo (subestimación severa) en P95-100, donde el MAE se multiplica entre 4 y 7 veces respecto al resto de la distribución. Es el comportamiento clásico de un modelo de regresión regresando hacia la media como la mayoría de los registros tiene salarios moderados, el modelo aprende a predecir cerca del centro de la distribución y le cuesta alcanzar los extremos, en especial el extremo alto, donde los salarios son relativamente raros y más dispersos.

Discusión

Random Forest superó consistentemente a la Regresión Lineal, tanto en validación (2025 T4) como en la prueba final (2026 T1), y ambos superaron con claridad al modelo de referencia. La brecha entre ambos algoritmos sugiere que existen interacciones no lineales entre los predictores sobre todo entre las variables categóricas y las numéricas que la Regresión Lineal no puede capturar. Aun así, ninguno de los dos modelos explica más de ~55 de la varianza del salario ($R^2 \approx 0.43 - 0.53$), con solo seis predictores personales/laborales, buena parte de la variación salarial observada queda sin explicar, lo cual es esperable dado que el salario depende también de factores no observados aquí (negociación individual, tamaño y sector específico de la empresa, desempeño, etc.).

El hallazgo más importante del análisis de residuos es que ambos modelos sobreestiman sistemáticamente los salarios bajos y subestiman fuertemente los

salarios altos, en particular el percentil 95-100. En términos prácticos, ninguno de los dos modelos es confiable para estimar el salario de las personas mejor pagadas de esta población, son más útiles para el grueso de trabajadores con salarios moderados. El error también varía por subgrupo, los niveles educativos asociados a salarios más altos tienden a mostrar mayor subestimación y mayor MAE absoluto, consistente con el patrón de percentiles, porque se concentran más en la cola alta de la distribución salarial.

La segmentación de la sección 6 y el modelado supervisado cuentan una historia coherente existen perfiles de trabajadores razonablemente distintos en antigüedad y edad, pero el salario mensual sigue siendo difícil de predecir con precisión únicamente a partir de características personales y laborales básicas, y esa dificultad se concentra específicamente en la cola alta de la distribución.

Referencias

- Instituto Nacional de Estadística de Guatemala (INE). Encuesta Nacional de Empleo e Ingresos Continua (ENEIC). <https://www.ine.gob.gt/encuesta-nacional-de-empleo-e-ingresos/>
- Apache Spark MLlib — Documentación oficial de pyspark.ml. <https://spark.apache.org/docs/3.5.1/ml-guide.html>

Link del Repositorio

La solución implementada se encuentra en el siguiente [repositorio](#) (clic en la imagen):

